



引言

GenAI 在 2025 年持续火热，Fortune 500 高管普遍认可其对企业运营的提升价值。

但当前 AI 市场存在严重的供需错配：开发者因部署成本高、知识产权难保护只能提供云端服务，无法深入企业构建护城河。传统企业急需 AI 赋能，但 SaaS 模式在行业深度和数据安全上存在硬伤，本地部署在拥有成本上产生巨大阻碍，无法获得好用且经济的解决方案。

我们认为，真正的破局之道是“行业 AI 应用 + 大模型 + 轻量化本地化部署”，

而市场上对这种轻量化解决方案的缺乏正是 AI 企业难盈利、AI 叙事难落地的根源。

产品是什么？

我们专为开发者打造了一台
能搭载模型和应用的超算，
助力快速交付





产品构想

一台专为快速交付落地而生的机器

RM-01 创新性地将模型推理（MIM）与应用部署及数据存储（ADM）彻底解耦，大幅简化了大模型部署的复杂性。该设备集成了专用的 ESP32 芯片

（SAM），统一负责硬件调度、加密鉴权并为连接的各类设备（如电脑、平板、手机）分配网络地址。用户操作极其简便：只需插入预装大型语言模型（LLM）的存储卡，模型即可在 MIM 上运行，并通过板载网络与 ADM 组件进行通信。关键的是，开发者和最终用户均无法直接访问 MIM 层，确保其核心运行环境的安全与稳定，即便在配置上层应用环境时也不会对其造成干扰。





RM-01作为企业和 AI 应用开发者之间的一座桥梁扫平了行业大模型加应用落地的技术难点和知识产权困境，吸引了更多应用开发者进入市场为企业开发应用，让解决行业实际问题的 AI 应用精准快速简单落地，打通了 AI 落地的最后一公里。



本地跑模型



本地跑应用



高数据安全




低拥有成本



开发者产权保护

产品特点



32/64/128G推理显存
一键 5 分钟内离线部署
千亿参数大模型

RMinte

独创一键部署技术，无需组装机箱，只需
将模型文件存入存储卡 →
将卡插入 RM-01 →
轻触开机键 →
5 分钟内即可开始使用，
操作简单到“不可思议”。



○○○ 24GB AI应用专属内存
○○○ + 8TB NVMe 存储



无论是 AI 应用开发平台还是行业定制化 AI 应用，机器提供 24GB x86架构的应用专属内存运行 docker image，同时为向量数据库提供 8TB NVMe 存储，保证了广泛的应用适配性。



网银级加密 保证数据安全

RMinte



用户数据全程本地化处理，即使断网也能全功能运行。IP5X 级密封工艺，防止物理拆解。独立加密模块，采用非对称硬件加密，即使设备丢失，数据仍保持加密状态，无法被破解或被读取。若强行拆机，数据将自动销毁，确保绝对安全。

超低拥有成本



超低100瓦功耗
无需 IDC 机房



一键开机
300 秒 AI 应用 Standby



卡带式管理
轻松切换应用



车规级稳定
0 运维成本





知识产权保护 促进生态良性循环

RMinte

独创 O 信任机制应用授权分发体系，通过硬件独有的公私钥，加密开发者分发的每一份应用，使其只能运行在唯一对应的机器上。这保护了开发者的知识产权，让市场去筛选“最优解”而不是“最廉价解”。

RM-01 使用方法

01

打开RM-01的磁吸盖板

02

插入存有AI模型和AI应用的存储卡

03

插上电源

04

等待300秒

05

用USB-C将RM-01连上你的
个人电脑/手机/网络交换机

06

打开个人设备

07

输入内网IP地址<http://10.10.99.99:59xxx>访问本地AI应用
(也可使用<http://10.10.99.98:58xxx>调用各类本地AI模型)

08

开始使用AI应用

核心参数 | RM-01系列部分适配模型运行结果

类别	规格	模型名称	单发推理速度	上下文长度	部署时间
算力能力	8高性能核心 + 12高效能核心 支持最高 275 (INT8) /2070 (FP4) 算力	Llama 3.1 8B	150.8/112.3 tokens/s	Max	77s
AI应用内存	最高24GB LPDDR5内存，支持8TB NVMe存储扩展	Qwen3-32B	79.1/20.7 tokens/s	Max	180s
模型列表	支持Llama、Qwen、GPT-OSS、智谱、DeepSeek、等300余种开源模型	Qwen2.5-72B	15.6/8 tokens/s	Max/18K	160s
并发能力	最大并发数:23/64 (建议数)	Qwen3-30B-A3B	226.4/76.7 tokens/s	Max	180s
功耗	最大功耗140/240 TDP60/130	Qwen2.5-VL-7B	252/154 tokens/s	Max	120s
物理规格	250.2mm x 166.5mm x 45.1mm	Qwen3-235B-A22B	82.6/- tokens/s	18K	420s
重量	1680g				
环境适应性	工作温度:-20℃ - 45℃				
安全特性	网银级非对称硬件加密，IP5X全密闭不可拆卸设计				

产品硬件架构



硬件参数

类别	Lite	Pro	Ultra
应用内存	最高 24GB LPDDR5 4800MT	最高 24GB LPDDR5 4800MT	最高 24GB LPDDR5 4800MT
推理内存	32GB 256 位 LPDDR5 275 TOPS (FP8) / 200 TOPS (INT8) （工业版本）	64GB 256 位 LPDDR5 275 TOPS (INT8) / 1200 TF LOPS (FP4) （工业版本）	128GB 256位 LPDDR5 2070 TFLOPS (FP4)
扩展存储	最高 8TB NVMe PCIe 3.0	最高 8TB NVMe PCIe 3.0	最高 8TB NVMe PCIe 3.0
上下文长度	最高 1M	最高 1M	最高 1M
加解密速度	15 万 TPS	15 万 TPS	15 万 TPS
USB 供电	USB PD3.1 协议 最高 140W	USB PD3.1 协议 最高 140W	USB PD3.1 协议 最高 240W
USB 有线网络	1G LAN USB-C	1G LAN USB-C	1G LAN USB-C
存储卡接口	CFexpress Type B卡槽 x 1 microSD 卡槽 x 1	CFexpress Type B 卡槽 x 1 microSD 卡槽 x 1	CFexpress Type B卡槽 x 1 microSD 卡槽 x 1
扩展槽	NVMe 2230 M.2 E-Key x 1 NVMe 2230 M.2 M-Key x 1，USB-C 2.0 x 1	NVMe 2230 M.2 E-Key x 1 NVMe 2230 M.2 M-Key x 1，USB-C 2.0 x 1	NVMe 2230 M.2 E-Key x 1 NVMe 2230 M.2 M-Key x 1，USB-C 2.0 x 1

应用场景示例

应用场景一

工业制造
离线产线规划

应用场景二

线下零售 / 服务
端侧智能化服务

应用场景三

政企行政办公
内部知识库问答

应用场景四

大模型基础服务建设
+ 离线智能体平台

应用场景一

工业制造 场景

离线智能产线规划

在工厂日常的高强度产线规划任务中，RM-01 通过搭载一套完整的 AI 产线规划应用，把本该耗时耗力编排的产线规划任务自动化，面对复杂多变的客户需求以及不定时的限电规定，产线规划人员只需要输入需求，RM-01 会自动根据工厂各类实际情况及限制迅速规划出最优排产方案，大幅减少工厂机器停机时间，提升生产效率。

RMinte



应用场景二

线下零售 场景

智能无人化便利店

通过搭载日本合作伙伴的AI多智能体管理系统，RM-01 以智能终端的形式在小范围的便利店中为顾客提供无人化智能服务，店内的摄像头、音频采集装置以及红外线传感器将数据通过局域网传输至 RM-01，经过多个智能体协同工作输出相应智能反馈至终端交互界面，为顾客提供无人化的智能购买体验，同时为店面运营监管提供智能店长能力，实时分析是否存在商品缺货，洒落等情况，保障门店业务正常运行。



应用场景三

智能问答 场景

离线震后智能决策系统

基于地震局历史数据与震后应急政策，智能决策系统在震后几分钟内抓取数据库中历史数据并匹配相应政策，秒级生成相应等级地震各部门单位的应对措施决策建议，经决策层审批，传达指令至相应部门以完成震后快速响应，响应速度从小时级别提升至秒级，效率提升超过数百倍，同时 AI 系统使用成本降低十倍。

RMinte

应用场景四

基座部署 场景

大模型基础设施部署

在与某大模型厂商合作的过程中，RM-01 完成了厂商旗下旗舰模型适配及闭源智能体平台适配，在该模型厂商承接的各类大模型基础设施建设项目中承担硬件基座的任务，为行业客户提供极为稳定的本地垂类大模型 + 多AI 应用集成平台的使用体验。



产品报道



“成都全制造 -
全球首个便携 AI 超算”

RM-R

具身智能背包

深度复刻人类大脑的分工与协同逻辑，构建从“感知-记忆-决策-执行”全链路高效运转的智能硬件底座

核心功能区，对应大脑关键中枢：

最高128G显存全量供给模型权重，如同大脑负责情感、交互、思考、决策的“核心认知区”，保障复杂运算的稳定输出；CPU专项支撑语言处理与前端数据处理，恰似大脑处理语言、解析信息的“语言中枢”与“感知整合区”，让信息交互更精准；板载内存则对应大脑的“短时记忆区”，快速暂存高频交互数据，实现即时性任务的高效响应。





硬件基础，模拟大脑神经与能量系统：

板上9000条高频线路，如同大脑中密集且高效的“神经传导网络”，确保各类数据信号极速传输；极大冗余的电容电感，好比大脑的“能量储备与调节中枢”，为全模块稳定运行提供持续且充足的动力支撑，避免因负载波动影响性能。

多模态模块，拓展大脑感知边界：

模块支持扩展多模态模块，可精准适配视觉、听觉等感知输入，如同为“智能大脑”配备了敏锐的“视觉中枢”与“听觉中枢”，大幅提升对复杂环境的感知能力；创新的卡带式模型部署同时兼容生成式模型、VLM模型与多模态模型，让“智能大脑”既能深度处理单一领域任务，又能整合多维度信息完成复杂决策，适配具身智能多样化应用场景。

模块化协同，复刻大脑网络调控逻辑：

各功能模块如同大脑中功能独立却紧密协作的脑区，既保持各自运算独立性，又可通过网络交换机实现高效“联动调控”API——开发人员可轻松完成模块间的数据交换与调用，如同大脑通过神经网络灵活调度各区域功能，进一步提升开发灵活性与系统运行效率。

高效落地，简化“智能大脑”部署流程：

对主板的深度工程化适配，仅需一根XT30电源通道即可完成全部电力部署，如同为“智能大脑”搭建了便捷的“能量供给通道”，大幅降低开发成本、缩短落地周期。


具身智能 脑背包 RM-R 规格参数

参数类别	详细描述	参数类别	详细描述
主板	RMinte™ 研主板	外围接	持：USB Power Delivery 协议 持：USB Type-C 接 提供最 140W电 传输 持：CFexpress Type B卡槽 × 1 持：microSD卡槽 × 1
应 模组处理器	持：Latte Panda Mu (x86) DFR1146/DFR1147/DFR1149 持：NVIDIA Arm® Cortex®-A78AE	机内扩展能	持：XT30 Male Plug × 2 持：NVMe 2230 M.2 E-Key × 1 持：NVMe 2230 M.2 M-Key × 1 持：10RMn GRMO Connector × 1
推理模组处理器	持：Jetson T5000/Jetson T4000 持：Jetson AGX Orin 持：业级 Jetson AGX Orin	模型和应 调度系统	RMinte™ ALTAI 模型及应 配置系统 持：LLM应 框架平台 持：定义应
应 内存	持：16/24GB LPDDR5 (4800MT/s)	硬件管理系统	持：模型服务调度 持：公钥/私钥 对称加密 持：电源管理 持：络接 和服务接 管理
推理显存	持：32GB/64GB/128GB	级互联技术	板对板 速直连 板间均衡负载
数据存储	持：扩展存储最 8TB NVMe PCIe 3.0 持：嵌 存储最 128G eMMC 5.0 400MB/s	持的操作系统	ALTAI

开箱即用 应用落地

RMinte

与各行业专家、开发者深度共创，已完成50+AI应用在RM-01上的适配工作，出厂即带50余种AI应用，做到真开箱即用。



开放生态资源

接入RM-01全球开发者社区，
共享行业案例与最佳实践。

专属技术支持

从模型优化到应用部署，
全程1对1技术指导。

共享商业渠道

即刻完成开发者认证，
加入生态合作伙伴名单，
共享商业资源与渠道。

开发者生态

RM-01不仅是硬件产品，更是完整的开发者生态系统。我们诚挚邀请您加入RM-01开发者社区，无论是初创团队还是资深开发者，您的每一份创新都值得被重视。

快速验证迭代

通过ALTAI系统，您可以快速验证、
开发和测试您的AI应用，
而无需担心复杂的底层技术和部署流程。

创新保障机制

知识产权全流程保护，
硬件级加密与0信任分发机制确保您的
创新成果得到充分保护和合理回报。

合作伙伴



制造业

上海智位机器人股份有限公司

零售业

让茶（浙江）饮品科技有限公司

服务业

四川阿瑞斯企业服务有限公司

信息技术业

四川先宇安通科技有限公司
四川旭特美科技有限公司
云睿科盛(海南)人工智能科技有限公司

文化传媒

上海辛卡司传媒科技有限公司
成都丕困文化传播有限公司

独立软件供应商

博彦科技
成都码酱信息科技有限公司

教育行业

成都迪泰未来科技有限公司
四川创驰云天科技有限公司

扫描手册封底二维码，欢迎加入我们的合作伙伴生态



 158 8200 8185

 support@rminte.com

 www.rminte.com

